

Технический отчёт

Агентная генерация вариантов использования и диаграмм деятельности по функциональным и нефункциональным требованиям

Университет ИТМО

Автор: Боцман Артём

Санкт-Петербург

Реферат

Работа посвящена подготовке проверяемых аналитических артефактов до генерации программного кода. Система принимает требования и формирует варианты использования, сценарные шаги, диаграммы деятельности и манифест трассировки. Реализованы типизированные модели, два специализированных графа LangGraph и ограниченные циклы проверки и исправления.

Отчёт обновляет постановку сравнения после замечаний комиссии. Добавлены усиленные внутренние базовые методы и внешняя агентная система OpenCode Build. Описаны исправления потока исходных данных, контракта проверки, обработки ответов и учёта ресурсов. Исторические результаты сохранены отдельно от новых опытов.

В серии на 59 и 74 функциональных требованиях FULL показал более высокий F1 смысловых этапов и меньшее время отдельных запусков, чем OpenCode. Структурные цепочки были полными у обоих методов. В серии размеров повышение F1 этапов сопровождалось снижением Recall. Эти результаты характеризуют конкретные методы, backend и условия; они не устанавливают универсальное превосходство по трассировке.

Ключевые слова: требования, Use Case, Activity Diagram, LangGraph, LLM, трассировка, формальная проверка, OpenCode.

Сокращения и обозначения

ФТ / FR — функциональное требование. НФТ / NFR — нефункциональное требование. UC — вариант использования. AD — диаграмма деятельности. LLM — языковая модель. FULL — полный граф; FULL_NEW — его исследовательский профиль. Gold — авторский кандидат эталонной разметки. E2E — исход полного выполнения. V1 и V2 — версии контракта проверки, а не версии модели.

Precision — доля сопоставленных элементов среди выданных системой. Recall — доля найденных элементов эталона. F1 — гармоническое среднее Precision и Recall. NA — значение не определено или недостаточно данных; это не ноль.

1. Цель, границы и задачи

Цель проекта — повысить качество и надёжность подготовки аналитических артефактов перед кодогенерацией: получать полные, формально корректные и трассируемые спецификации. Это цель сравнения, а не заранее достигнутое преимущество по каждому показателю.

Система не создаёт полное техническое задание или архитектуру программного кода. Её результат — промежуточный пакет Use Cases, сценарных шагов, Activity Diagrams, Mermaid и TraceManifest. Манифест позволяет пройти от требования к сценарию и далее к элементам диаграммы, а также найти исходное требование для элемента результата.

Задачи работы: определить типизированные модели; реализовать два специализированных графа и оркестратор; добавить формальные проверки, критику и ограниченное исправление; подготовить benchmark и метрики; сравнить полный метод с внутренними baseline и внешним агентным решением при зафиксированных условиях.

Технический вклад состоит в совместной реализации типизированного пакета, явных ссылок происхождения, детерминированных проверок и ограниченной обратной связи внутри графа. Вклад проверяется работающим кодом и наблюдаемыми результатами. Приоритет такого сочетания перед всеми существующими решениями отдельно не устанавливался.

Проверяются три разных вопроса: доставлен ли пакет; согласованы ли его ссылки и структура; насколько его содержание соответствует эталону. Успех в одном вопросе не заменяет остальные. Например, правильная ссылка на требование ещё не означает, что все его условия отражены в сценарии.

Гипотеза: специализированная подготовка сценариев и проверка связей может улучшать отдельные показатели относительно универсального агента. Анализ размера предварительный: по два проекта на группу, размер смешан с предметной областью.

2. Архитектура и поток данных

Вход SpecificationReq содержит описание проекта, функциональные и нефункциональные требования. После нормализации требования получают устойчивые идентификаторы. Первый граф создаёт Use Cases и шаги, второй строит Activity для каждого сценария. Затем формируются Mermaid, TraceManifest и отчёты проверки.

Граф	Генератор	Критик	Редактор
Use Cases	Создаёт сценарии из требований	Проверяет содержание и согласованность	Исправляет текущие замечания
Activity	Строит граф по UC	Сверяет диаграмму с UC и источником	Исправляет диаграмму

Генератор, критик и редактор — роли обращения к LLM, а не шесть разных моделей. Критик формулирует смысловые замечания. Валидаторы проверяют типы, ссылки и свойства графа программно. При формальных ошибках критик может не вызываться: редактор получает ошибки валидатора. После не более двух исправлений соответствующий цикл принимает результат либо фиксирует отказ.

Трассировка проходит по идентификаторам: ФТ → UC → сценарный шаг → действие или переход Activity. Проверяются существование объектов, принадлежность шага нужному UC и достижимость действий по допустимому пути. Обратные связи сохраняются в TraceManifest. НФТ передаются как исходный контекст и связываются с UC; полная смысловая проверка каждого НФТ этим не обеспечивается.

OpenCode не является частью этой архитектуры. Экспериментальный стенд независимо запускает FULL и OpenCode, собирает их файлы и применяет общий оценщик. Поэтому внешний baseline не помогает нашему графу создавать его результат.

3. Исправления реализации

Полный исходный контекст раньше получал прежде всего генератор UC. Теперь единый блок исходных данных передаётся всем шести ролям. Критики сверяют ответ с источником, а редакторы исправляют ошибки с учётом всех требований.

Текущие замечания отделены от истории проверок. Редактор получает ошибки, относящиеся к редактируемой версии; прежние отчёты сохраняются для аудита. Критик уже раньше видел актуальный результат: аудит обнаружил это в 68 из 68 старых и 204 из 204 новых проверок, включая 12 проверок после исправления. Поэтому получение свежей версии результата не представляется как новая доработка.

Критик и редактор Activity получают словарь акторов — перечень участников из UC. Он нужен для согласования названий и ролей: например, «администратор» в сценарии и на диаграмме должен обозначать одного участника.

Уточнён терминальный поток Activity. Проверяются начало, конец и достижимость действий; обход не продолжается после конечного узла. Наличие пути к действию после фиктивного завершения больше не засчитывается как корректная цепочка. Это проверка структуры, а не понимания бизнес-смысла действия.

V1 требовал ссылку или явное основание у каждого элемента, включая служебные переходы. V2 допускает узкое исключение для перехода от начала или к концу: концы существуют, нет подписи и условия, переход не является выходом решения. Ошибочные ID, бизнес-действия и внутренние переходы проверяются. Дополнительно проверяются ссылки UC на НФТ. Формально допустимое неподтверждённое предположение учитывается отдельно от ссылки на источник.

Потоковые ответы собираются полностью, причины завершения и обрезания записываются. Обновлён учёт стоимости, резервов и неизвестного расхода. Отсутствие usage не превращается в нулевую цену.

4. Постановка внешнего сравнения

Сравнивались исследовательский FULL_NEW и штатный агент OpenCode Build версии 1.18.33. В обоих случаях backend — deepseek-flash. Модель служит общим генератором текста; сравниваются способы организации её работы, а не разные модели.

OpenCode запускался отдельным процессом через CLI. Разрешены чтение задания, запись файлов результата и список задач. Shell, сеть, MCP, доступ к Gold и исходникам FULL отключены. Наши критики и редакторы OpenCode не передавались. Общий импортёр формировал совместимые представления Mermaid и TraceManifest без смыслового исправления ответа.

Параметр	Оба метода в новых cap2/размерных сериях
Модель / параметры	deepseek-flash; T=0,2; thinking disabled
На один ответ	До 131072 выходных токенов
На попытку	До \$2 и 512 вызовов; 3600 с активного выполнения
Токены суммарно	Отдельный потолок не задан; действует бюджет
Остановка	Расход начатых вызовов учитывается после остановки
Оценка	Одинаковый контракт, Gold и matcher после генерации

Одинаковы исходные требования, контракт выходного пакета, backend, фактические параметры генерации и внешние ограничения. Внутренние шаги, подсказки и число вызовов различаются — это часть сравниваемых методов. Ограниченный Build не представляет все возможности OpenCode или его отдельного агента Plan.

Thinking отключён как зафиксированное условие, позволяющее сравнивать методы без дополнительного режима рассуждения и его расходов. Это не доказательство, что такой режим оптимален. DeepSeek выбран как доступный по бюджету единый backend. Новые серии не устанавливают, что он качественнее GPT или Claude.

На 59 и 74 ФТ выполнены четыре cap2 запуска, отдельно от старой cap1 серии. В серии размеров: 6/10/12/19/24/48 ФТ, два метода, два повтора, всего 24 попытки. Отказы автоматически не повторялись. Разрешённые диагностические повторы имеют отдельные ID.

5. Методика оценки

Первая основная метрика — доля ФТ с явной цепочкой до достижимого действия Activity по терминально корректному пути. Вторая — доля элементов Activity с допустимым основанием по контракту V2. Основания разделены на корректную ссылку, структурный элемент, явное неподтверждённое предположение и ошибки. Значение 1 по V2 не означает 100% смысловой полноты.

Содержание оценивается по пяти группам: Actor — участники; UC — варианты использования; Milestone — смысловые этапы; Branch — альтернативы и ветвления; Trace — связи ФТ с сопоставленными UC. Для каждой группы публикуются Precision, Recall и F1. Trace F1 не оценивает всю цепочку вплоть до действия диаграммы.

Gold — авторский кандидат, подготовленный с использованием LLM. Это не независимая экспертная разметка. Применяется прежний фиксированный matcher с локальными эмбедами; пороги не подбираются под новые результаты. Независимая проверка уменьшения неоднозначности требует отдельной оценки людей или внешних тестов кода.

Рост F1 может сочетаться со снижением Recall: более короткий и точный ответ содержит меньше лишних элементов, но пропускает больше эталонных. Такой исход называется улучшением баланса Precision/Recall, а не лучшим сохранением всех требований.

В серии размеров сначала усредняются доступные общие повторы внутри проекта, затем проектам назначается равный вес. Для Gold доступны 4, 2 и 4 пары по трём группам; для структурных метрик — 4, 3 и 4. Частичный FULL на 12 ФТ не подменяется нулём. Известный отказ без пакета даёт нулевую доставку структуры, но Gold остаётся NA.

Ресурсы включают время, вызовы, токены, цену, обрезания и исход. Токены считают повторно передаваемый контекст; это не объём уникальных требований. Стоимость зависит также от кеша и тарифа. Сумма времени отказов не является оценкой скорости успешной доставки.

6. Большие проекты: содержание

Четыре cap2 запуска завершились естественно, без обрезания. В таблице показаны все пять метрик относительно одного кандидата Gold. P — Precision, R — Recall. Значения округлены до трёх знаков только при отображении.

ФТ / метод	Метрика	P	R	F1
59 / OpenCode	Actor	1,000	0,909	0,952
59 / OpenCode	UC	1,000	0,963	0,981
59 / OpenCode	Milestone	0,357	0,953	0,519
59 / OpenCode	Branch	0,111	0,556	0,185
59 / OpenCode	Trace	0,966	0,966	0,966
59 / FULL	Actor	1,000	1,000	1,000
59 / FULL	UC	1,000	1,000	1,000
59 / FULL	Milestone	0,520	1,000	0,684
59 / FULL	Branch	1,000	0,556	0,714
59 / FULL	Trace	1,000	1,000	1,000
74 / OpenCode	Actor	0,857	0,750	0,800
74 / OpenCode	UC	1,000	1,000	1,000
74 / OpenCode	Milestone	0,300	0,949	0,456
74 / OpenCode	Branch	0,119	0,381	0,182
74 / OpenCode	Trace	1,000	1,000	1,000
74 / FULL	Actor	0,750	0,750	0,750
74 / FULL	UC	1,000	1,000	1,000
74 / FULL	Milestone	0,500	0,873	0,636
74 / FULL	Branch	0,200	0,048	0,077
74 / FULL	Trace	0,986	0,986	0,986

На 59 ФТ FULL получил более высокий F1 этапов, ветвлений и связей. Recall ветвлений одинаков: найдены 5 из 9 эталонных ветвей. Выигрыш Branch F1 связан с Precision, а не с обнаружением большего числа ветвей.

На 74 ФТ Milestone F1 FULL выше, но Recall ниже: сопоставлены 69 из 79 этапов против 75 из 79 у OpenCode. Для ветвей FULL сопоставил 1 из 21 против 8 из 21 у OpenCode. Trace F1 здесь немного ниже. Поэтому общий вывод ограничен наблюдаемым выигрышем по F1 этапов; устойчивое преимущество по всем связям или ветвям не установлено.

7. Большие проекты: структура и ресурсы

ФТ / метод	Секунды	Вызовы	Токены	Цена, \$
59 / OpenCode	613,1	141	17 699 749	0,149200
59 / FULL	459,5	118	1 455 979	0,234667
74 / OpenCode	1043,4	244	41 099 626	0,288357
74 / FULL	658,3	145	2 080 277	0,347056

FULL завершился быстрее на 25,1% при 59 ФТ и на 36,9% при 74 ФТ. Это время отдельных запусков, без доверительного интервала. Цена FULL выше соответственно на 57,3% и 20,4%. Большой объём повторяемого контекста OpenCode частично компенсировался кешированием, поэтому меньше токенов не обязательно означает меньшую цену.

ФТ / метод	Цепочки	V2	Ссылка	Служебный	Явное допущение
59 / OpenCode	59/59	671/671	509	162	0
59 / FULL	59/59	502/502	337	165	0
74 / OpenCode	74/74	972/972	771	201	0
74 / FULL	74/74	707/707	505	196	6

Оба метода получили 100% структурных цепочек и допустимых оснований V2. В таблице разделены ссылки, служебные элементы и явные неподтверждённые предположения без ссылки. У FULL на 74 ФТ шесть элементов относятся к последней категории; всего семь помечены unsupported, один также имеет ссылку. Ошибочных ссылок и отсутствующих оснований нет. Таким образом, V2=1 не означает, что каждый элемент подтверждён источником.

Разница Trace F1 на 59 ФТ не означает автоматически два потерянных требования OpenCode. При локальном разборе функции присутствовали, но были сгруппированы в UC иначе, чем в Gold. Сопоставление UC влияет на оценку связей. Числовой Trace и проверка явных структурных цепочек отвечают на разные вопросы.

8. Серия размеров: исходные 24 попытки

Использованы шесть проектов руководителя: SCALE-001/005/006/010/011/015, соответственно 6/10/12/19/24/48 ФТ. По два повтора FULL и OpenCode. Все исходные попытки сохранены; диагностические повторы не включены в приведённые средние.

Группа	Метрика	FULL P/R/F1	OpenCode P/R/F1
6–10 ФТ	Actor	0,917 / 1,000 / 0,950	1,000 / 1,000 / 1,000
6–10 ФТ	UC	1,000 / 1,000 / 1,000	1,000 / 1,000 / 1,000
6–10 ФТ	Milestone	0,510 / 0,882 / 0,643	0,383 / 0,951 / 0,543
6–10 ФТ	Branch	0,167 / 0,667 / 0,167	0,049 / 0,667 / 0,075
6–10 ФТ	Trace	0,909 / 0,950 / 0,929	0,955 / 0,975 / 0,964
12–19 ФТ	Actor	1,000 / 1,000 / 1,000	0,875 / 0,875 / 0,875
12–19 ФТ	UC	1,000 / 1,000 / 1,000	1,000 / 1,000 / 1,000
12–19 ФТ	Milestone	0,395 / 0,857 / 0,536	0,273 / 0,875 / 0,416
12–19 ФТ	Branch	0,220 / 0,875 / 0,343	0,084 / 0,750 / 0,146
12–19 ФТ	Trace	0,974 / 0,974 / 0,974	1,000 / 1,000 / 1,000
24–48 ФТ	Actor	0,851 / 0,887 / 0,868	0,917 / 0,810 / 0,856
24–48 ФТ	UC	1,000 / 1,000 / 1,000	1,000 / 1,000 / 1,000
24–48 ФТ	Milestone	0,441 / 0,809 / 0,568	0,366 / 0,871 / 0,510
24–48 ФТ	Branch	0,550 / 0,417 / 0,473	0,188 / 0,750 / 0,296
24–48 ФТ	Trace	0,979 / 0,979 / 0,979	0,979 / 0,979 / 0,979

Формально принятые полные пакеты: FULL 9/12, OpenCode 11/12. FULL на 10 ФТ в первом повторе и 48 ФТ во втором остановился до Activity после неисправленных замечаний. OpenCode на 19 ФТ в первом повторе завершился обрезанием без пакета. FULL на 12 ФТ во втором повторе прерван после HTTP 402; его расход известен не полностью.

Средняя доставка структурных цепочек FULL/OpenCode: 0,75/1,00 для 6–10 ФТ; 1,00/0,75 для 12–19; 0,75/1,00 для 24–48. Эти числа учитывают отказы и не доказывают общее преимущество FULL по трассировке.

Известная цена серии — \$3,213963216; верхний учёт — \$3,381197916. Разница \$0,167234700 является резервом неизвестного расхода, а не измеренной ценой. Различия тарифных условий и исходов ограничивают выводы о сравнительной экономичности.

9. Температура и диагностические повторы

Температура управляет вариативностью выбора продолжения текста моделью. При $T=0$ ответы обычно менее вариативны, но абсолютная повторяемость не гарантируется. При ненулевой T возможны разные формулировки и сценарные решения. Температура не меняет алгоритм валидаторов или лимит исправлений.

Пилот: два других проекта на 7 и 9 ФТ, два метода, $T=0/0,2/0,7$, два повтора — 24 запланированные попытки. Завершено 16: восемь при $T=0$ и по четыре при $T=0,2$ и $0,7$. Восемь не начаты из-за бюджетного барьера. Известный расход \$1,004585226; обрезаний нет. FULL формально принят в 8/8, OpenCode — в 7/8.

Заранее заданное правило выбора: при неполной или неуспешной сетке либо отсутствии практического прироста сохраняется 0,2. Поэтому 0,2 — фиксированная рабочая настройка, а не доказанный оптимум. $T=1$ не проверялась. Повторы на $T=0$ не используются как независимая выборка для сильных статистических выводов. Ненулевая температура тоже сама по себе не доказывает независимость.

После исходной серии размеров отдельно повторены четыре проблемные позиции: FULL10 r1, OpenCode19 r1, FULL12 r2, FULL48 r2. Все четыре новые попытки дали полный пакет, цепочки и $V2=1$, без обрезаний; цена новых попыток \$0,297469080. Это показывает возможность успешного завершения повторного запуска, но не исправляет статистику первоначальных 24 попыток и не доказывает устранение причины отказов.

Все исходные и новые task ID, метрики P/R/F1 и ресурсы доступны в числовом приложении. Для двух отказов FULL сохранённый UC-пакет допускает часть Gold-оценок; это не превращает его в полный пакет с Activity. Неизвестный исторический расход остаётся неизвестным и после успешного диагностического повтора.

10. Ответ на замечания комиссии

1. «Отсутствует нормальный бейзлайн». Добавлены запрос с одной правкой, разбиение по UC и настоящий OpenCode Build. На историческом DEV20 по общей V1-проверке: один запрос 0/60; одна правка 59/60; разбиение 0/60; FULL 59/60. Это другая серия и другой способ итоговой проверки, чем прежние 2/60 и 60/60; числа не подменяются. Ничья с одной правкой учтена в выводах.

2. «Лимит там выставлен 8000 токенов». Новые исследовательские серии используют 131072 выходных токена на ответ с фиксацией причины остановки. Старый демонстрационный CLI-лимит не используется для описания этих опытов. Четыре cap2 ответа завершились без обрезаний.

3. «Любое разбиение на части промта ... решает эту проблему». Разбиение выделено в самостоятельный baseline без критика. Размер ответа и формальная приёмка разделены. Сам по себе отказ разбиения не доказывает необходимость критика. Контроль на заданных ответах проверяет механизм ограниченного исправления, но не качество LLM.

4. «Мотивация ... никогда не проверялось, поскольку нет разметки человеком». Опубликованы все пять P/R/F1 и разделены структурная корректность и смысл. В отдельном внешнем опыте 11 формально принятых FULL-пакетов всё же дали неуспешную кодогенерацию. Это обосновывает необходимость внешней проверки, но не доказывает преимущество FULL. Независимая экспертная оценка остаётся открытым пунктом.

5. «Не называть независимыми запуски на температуре 0». Новые сравнения выполнены при фактической $T=0,2$; проведён отдельный калибровочный пилот. Для малых серий не заявлены статистическая значимость и универсальная устойчивость.

6. «Фреймворк ... не используются как бейзлайны». Выполнено числовое сравнение с OpenCode Build. NOMAD не запускался и остаётся только теоретическим аналогом. Сравнение backend-моделей отделено от сравнения методов.

11. Воспроизводимость и опубликованные изменения

Опубликованы исправления промптов, передача исходного контекста, проверки терминального потока, исследовательский профиль, внешний адаптер, учёт ответов и регрессионные тесты. Закрытые требования, приватные журналы и API-ключи не публикуются.

Обычный CLI FULL сохраняет прежний профиль. FULL_NEW использовал `terminal_consistency_deps` с `contract_version=V2` и `CacheAwareFullClient`. Адаптер передавал $T=0,2$ даже при запросе роли $T=0$. Контракт V2 температуру не меняет. Предел \$2 задавался обёрткой серии, не старым адаптером по умолчанию.

`results_snapshot.json` содержит числа и статусы четырёх серий, включая не начатые позиции и отказы. Хеши `summary.json` фиксируют происхождение. Срез позволяет проверить сводные числа, но не повторно оценить закрытый Gold.

Безопасная проверка установки: `poetry install --with evaluation`, затем демонстрация B0_RULE на `examples/event_signup_specification_req.json`. Этот режим не использует API. Локальные регрессионные тесты запускаются через `poetry run pytest`. Сетевой запуск требует отдельного разрешения `--allow-live` и собственных лимитов.

Заключение

Реализован проверяемый промежуточный пакет требований, сценариев и диаграмм. Исправлен поток исходного контекста и обратной связи, усилены проверки потока Activity и постановка сравнения. Добавлен внешний агентный baseline с общим backend и явными ограничениями.

На двух больших проектах наблюдается преимущество FULL по Milestone F1 и времени отдельных запусков. Цена выше; результаты по ветвлениям и трассировке неоднородны. В серии размеров более высокий F1 не означает более высокий Recall. Наиболее обоснованный итог — работоспособная реализация и измеренные преимущества в обозначенных условиях, с сохранением отрицательных результатов и границ применимости.

Приложение. Источники и проверяемость

Источниками обновления служат локальные зафиксированные протоколы, исходный код, контрольные срезы результатов и прежний технический отчёт. Новые статьи и внешние материалы для этого обновления не ищались. Новые платные эксперименты не проводились.

Контрольный срез	SHA-256 исходного summary.json
large_cap2	2ff1b8033876ae5027f12da45c7336b2 0f169bba87b4a6c57820e067ce6ba30f
sizes_original24	06e3ab5858847dc74e75614f378cd577 242e594627acae864b8c9453f74d61a1
temperature_pilot	a6d7d852085774fa65ca93ee7c3fb091 6bc46cf3a8a97851e5a6793b05c47649
diagnostic_retries	8289e27341aecb1e9411a64d89b2e28e a6f12de4cbafa4400b8bf6ab4ea94b37

Карта опубликованных материалов: README.md — краткая постановка и запуск; docs/final/CHANGES_AND_REVIEW.md — замечания комиссии и ответы; docs/final/results/results_snapshot.json — точные числовые данные; docs/final/REPORT_SOURCE.md — исходный текст отчёта; scripts/build_public_report.py — сборка PDF.

Встроенные таблицы формируются из числового приложения, а не переписываются вручную. Первоначальные отчёты и результаты сохранены как исторические. Новая публикация не меняет условия уже выполненных опытов и не выбирает лучший ответ из первоначального и диагностического запуска.

Оформление основано на прежнем техническом отчёте: А4, чёрный текст, Times New Roman, основной кегль 14, межстрочный интервал 1,5, поля слева 3 см, справа 1,5 см, сверху и снизу 2 см. Календарные даты и время суток в новом документе отсутствуют; длительность запусков сохранена как существенная метрика.