

Технический отчёт

Агентная генерация вариантов использования и диаграмм деятельности по функциональным и нефункциональным требованиям

Университет ИТМО

Автор: Боцман Артём

Санкт-Петербург

Реферат

Работа посвящена подготовке проверяемых аналитических артефактов до генерации программного кода. Система принимает требования и формирует варианты использования, сценарные шаги, диаграммы деятельности и манифест трассировки. Реализованы типизированные модели, два специализированных графа LangGraph и ограниченные циклы проверки и исправления.

Отчёт обновляет постановку сравнения после замечаний комиссии. Добавлены усиленные внутренние базовые методы и внешняя агентная система OpenCode Build. Описаны исправления потока исходных данных, контракта проверки, обработки ответов и учёта ресурсов. Исторические результаты сохранены отдельно от новых опытов.

В серии на 59 и 74 функциональных требованиях FULL показал более высокий F1 смысловых этапов и меньшее время отдельных запусков, чем OpenCode. Структурные цепочки были полными у обоих методов. В серии размеров повышение F1 этапов сопровождалось снижением Recall. Эти результаты характеризуют конкретные методы, backend и условия; они не устанавливают универсальное превосходство по трассировке.

Ключевые слова: требования, Use Case, Activity Diagram, LangGraph, LLM, трассировка, формальная проверка, OpenCode.

Сокращения и обозначения

ФТ / FR — функциональное требование. НФТ / NFR — нефункциональное требование. UC — вариант использования. AD — диаграмма деятельности. LLM — языковая модель. FULL — полный граф; FULL_NEW — его исследовательский профиль. Gold — авторский кандидат эталонной разметки. E2E — исход полного выполнения. V1 и V2 — версии контракта проверки, а не версии модели.

Precision — доля сопоставленных элементов среди выданных системой. Recall — доля найденных элементов эталона. F1 — гармоническое среднее Precision и Recall. NA — значение не определено или недостаточно данных; это не ноль.

1. Цель, границы и задачи

Цель проекта — повысить качество и надёжность подготовки аналитических артефактов перед кодогенерацией: получать полные, формально корректные и трассируемые спецификации. Это цель сравнения, а не заранее достигнутое преимущество по каждому показателю.

Система не создаёт полное техническое задание или архитектуру программного кода. Её результат — промежуточный пакет Use Cases, сценарных шагов, Activity Diagrams, Mermaid и TraceManifest. Манифест позволяет пройти от требования к сценарию и далее к элементам диаграммы, а также найти исходное требование для элемента результата.

Задачи работы: определить типизированные модели; реализовать два специализированных графа и оркестратор; добавить формальные проверки, критику и ограниченное исправление; подготовить benchmark и метрики; сравнить полный метод с внутренними baseline и внешним агентным решением при зафиксированных условиях.

Технический вклад состоит в совместной реализации типизированного пакета, явных ссылок происхождения, детерминированных проверок и ограниченной обратной связи внутри графа. Вклад проверяется работающим кодом и наблюдаемыми результатами. Приоритет такого сочетания перед всеми существующими решениями отдельно не устанавливался.

Проверяются три разных вопроса: доставлен ли пакет; согласованы ли его ссылки и структура; насколько его содержание соответствует эталону. Успех в одном вопросе не заменяет остальные. Например, правильная ссылка на требование ещё не означает, что все его условия отражены в сценарии.

Гипотеза: специализированная подготовка сценариев и проверка связей может улучшать отдельные показатели относительно универсального агента. Анализ размера предварительный: по два проекта на группу, размер смешан с предметной областью.

2. Архитектура и поток данных

Вход SpecificationReq содержит описание проекта, функциональные и нефункциональные требования. После нормализации требования получают устойчивые идентификаторы. Первый граф создаёт Use Cases и шаги, второй строит Activity для каждого сценария. Затем формируются Mermaid, TraceManifest и отчёты проверки.

Граф	Генератор	Критик	Редактор
Use Cases	Создаёт сценарии из требований	Проверяет содержание и согласованность	Исправляет текущие замечания
Activity	Строит граф по UC	Сверяет диаграмму с UC и источником	Исправляет диаграмму

Генератор, критик и редактор — роли обращения к LLM, а не шесть разных моделей. Критик формулирует смысловые замечания. Валидаторы проверяют типы, ссылки и свойства графа программно. При формальных ошибках критик может не вызываться: редактор получает ошибки валидатора. После не более двух исправлений соответствующий цикл принимает результат либо фиксирует отказ.

Трассировка проходит по идентификаторам: ФТ → UC → сценарный шаг → действие или переход Activity. Проверяются существование объектов, принадлежность шага нужному UC и достижимость действий по допустимому пути. Обратные связи сохраняются в TraceManifest. НФТ передаются как исходный контекст и связываются с UC; полная смысловая проверка каждого НФТ этим не обеспечивается.


OpenCode не является частью этой архитектуры. Экспериментальный стенд независимо запускает FULL и OpenCode, собирает их файлы и применяет общий оценщик. Поэтому внешний baseline не помогает нашему графу создавать его результат.

Рисунок 1. Архитектура полного метода

Архитектура и исправления


ИТМО

Корневой оркестратор: нормализация, ID, состояние и сборка



В каждом графе: генератор, критик, редактор; до двух исправлений
Код проверяет структуру, LLM-критик ищет смысловые ошибки

**Правки: список участников для критика и редактора;
проверка связности и границ диаграммы**



Проверки структуры существовали раньше. Изменен поток данных и контроль согласованности.

2

На схеме показан корневой оркестратор и два специализированных графа. Полный исходный контекст доступен всем шести ролям: генератору, критику и редактору Use Cases и Activity. Каждый цикл ограничен двумя исправлениями.

Внешний оценщик находится за пределами генерации. Gold не передаётся генераторам. Отдельные тесты кодогенерации относятся к самостоятельному опыту, а не ко всем новым запускам OpenCode. Сам OpenCode на этой схеме отсутствует: это внешний конкурент, не компонент FULL.

Чёрно-белая схема перенесена из подготовленной презентации. Основная структура из двух графов сохранена; исправлены полнота передаваемого контекста, текущая обратная связь и контроль согласованности.

3. Исправления реализации

Полный исходный контекст раньше получал прежде всего генератор UC. Теперь единый блок исходных данных передаётся всем шести ролям. Критики сверяют ответ с источником, а редакторы исправляют ошибки с учётом всех требований.

Текущие замечания отделены от истории проверок. Редактор получает ошибки, относящиеся к редактируемой версии; прежние отчёты сохраняются для аудита. Критик уже раньше видел актуальный результат: аудит обнаружил это в 68 из 68 старых и 204 из 204 новых проверок, включая 12 проверок после исправления. Поэтому получение свежей версии результата не представляется как новая доработка.

Критик и редактор Activity получают словарь акторов — перечень участников из UC. Он нужен для согласования названий и ролей: например, «администратор» в сценарии и на диаграмме должен обозначать одного участника.

Уточнён терминальный поток Activity. Проверяются начало, конец и достижимость действий; обход не продолжается после конечного узла. Наличие пути к действию после фиктивного завершения больше не засчитывается как корректная цепочка. Это проверка структуры, а не понимания бизнес-смысла действия.

V1 требовал ссылку или явное основание у каждого элемента, включая служебные переходы. V2 допускает узкое исключение для перехода от начала или к концу: концы существуют, нет подписи и условия, переход не является выходом решения. Ошибочные ID, бизнес-действия и внутренние переходы проверяются. Дополнительно проверяются ссылки UC на НФТ. Формально допустимое неподтверждённое предположение учитывается отдельно от ссылки на источник.

Потоковые ответы собираются полностью, причины завершения и обрезания записываются. Обновлён учёт стоимости, резервов и неизвестного расхода. Отсутствие usage не превращается в нулевую цену.

4. Постановка внешнего сравнения

Сравнивались исследовательский FULL_NEW и штатный агент OpenCode Build версии 1.18.33. В обоих случаях backend — deepseek-flash. Модель служит общим генератором текста; сравниваются способы организации её работы, а не разные модели.

OpenCode запускался отдельным процессом через CLI. Разрешены чтение задания, запись файлов результата и список задач. Shell, сеть, MCP, доступ к Gold и исходникам FULL отключены. Наши критики и редакторы OpenCode не передавались. Общий импортёр формировал совместимые представления Mermaid и TraceManifest без смыслового исправления ответа.

Параметр	Оба метода в новых cap2/размерных сериях
Модель / параметры	deepseek-flash; T=0,2; thinking disabled
На один ответ	До 131072 выходных токенов
На попытку	До \$2 и 512 вызовов; 3600 с активного выполнения
Токены суммарно	Отдельный потолок не задан; действует бюджет
Остановка	Расход начатых вызовов учитывается после остановки
Оценка	Одинаковый контракт, Gold и matcher после генерации

Одинаковы исходные требования, контракт выходного пакета, backend, фактические параметры генерации и внешние ограничения. Внутренние шаги, подсказки и число вызовов различаются — это часть сравниваемых методов. Ограниченный Build не представляет все возможности OpenCode или его отдельного агента Plan.

Thinking отключён как зафиксированное условие, позволяющее сравнивать методы без дополнительного режима рассуждения и его расходов. Это не доказательство, что такой режим оптимален. DeepSeek выбран как доступный по бюджету единый backend. Новые серии не устанавливают, что он качественнее GPT или Claude.

На 59 и 74 ФТ выполнены четыре cap2 запуска, отдельно от старой cap1 серии. В серии размеров: 6/10/12/19/24/48 ФТ, два метода, два повтора, всего 24 попытки. Отказы автоматически не повторялись. Разрешённые диагностические повторы имеют отдельные ID.

5. Методика оценки

Первая основная метрика — доля ФТ с явной цепочкой до достижимого действия Activity по терминально корректному пути. Вторая — доля элементов Activity с допустимым основанием по контракту V2. Основания разделены на корректную ссылку, структурный элемент, явное неподтверждённое предположение и ошибки. Значение 1 по V2 не означает 100% смысловой полноты.

Содержание оценивается по пяти группам: Actor — участники; UC — варианты использования; Milestone — смысловые этапы; Branch — альтернативы и ветвления; Trace — связи ФТ с сопоставленными UC. Для каждой группы публикуются Precision, Recall и F1. Trace F1 не оценивает всю цепочку вплоть до действия диаграммы.

Gold — авторский кандидат, подготовленный с использованием LLM. Это не независимая экспертная разметка. Применяется прежний фиксированный matcher с локальными эмбедами; пороги не подбираются под новые результаты. Независимая проверка уменьшения неоднозначности требует отдельной оценки людей или внешних тестов кода.

Рост F1 может сочетаться со снижением Recall: более короткий и точный ответ содержит меньше лишних элементов, но пропускает больше эталонных. Такой исход называется улучшением баланса Precision/Recall, а не лучшим сохранением всех требований.

В серии размеров сначала усредняются доступные общие повторы внутри проекта, затем проектам назначается равный вес. Для Gold доступны 4, 2 и 4 пары по трём группам; для структурных метрик — 4, 3 и 4. Частичный FULL на 12 ФТ не подменяется нулём. Известный отказ без пакета даёт нулевую доставку структуры, но Gold остаётся NA.

Ресурсы включают время, вызовы, токены, цену, обрезания и исход. Токены считают повторно передаваемый контекст; это не объём уникальных требований. Стоимость зависит также от кеша и тарифа. Сумма времени отказов не является оценкой скорости успешной доставки.

6. Большие проекты: содержание



Четыре cap2 запуска завершились естественно, без обрезания. В таблице показаны все пять метрик относительно одного кандидата Gold. P — Precision, R — Recall. Значения округлены до трёх знаков только при отображении.

ФТ / метод	Метрика	P	R	F1
59 / OpenCode	Actor	1,000	0,909	0,952
59 / OpenCode	UC	1,000	0,963	0,981
59 / OpenCode	Milestone	0,357	0,953	0,519
59 / OpenCode	Branch	0,111	0,556	0,185
59 / OpenCode	Trace	0,966	0,966	0,966
59 / FULL	Actor	1,000	1,000	1,000
59 / FULL	UC	1,000	1,000	1,000
59 / FULL	Milestone	0,520	1,000	0,684
59 / FULL	Branch	1,000	0,556	0,714
59 / FULL	Trace	1,000	1,000	1,000
74 / OpenCode	Actor	0,857	0,750	0,800
74 / OpenCode	UC	1,000	1,000	1,000
74 / OpenCode	Milestone	0,300	0,949	0,456
74 / OpenCode	Branch	0,119	0,381	0,182
74 / OpenCode	Trace	1,000	1,000	1,000
74 / FULL	Actor	0,750	0,750	0,750
74 / FULL	UC	1,000	1,000	1,000
74 / FULL	Milestone	0,500	0,873	0,636
74 / FULL	Branch	0,200	0,048	0,077
74 / FULL	Trace	0,986	0,986	0,986

На 59 ФТ FULL получил более высокий F1 этапов, ветвлений и связей. Recall ветвлений одинаков: найдены 5 из 9 эталонных ветвей. Выигрыш Branch F1 связан с Precision, а не с обнаружением большего числа ветвей.

На 74 ФТ Milestone F1 FULL выше, но Recall ниже: сопоставлены 69 из 79 этапов против 75 из 79 у OpenCode. Для ветвей FULL сопоставил 1 из 21 против 8 из 21 у OpenCode. Trace F1 здесь немного ниже. Поэтому общий вывод ограничен наблюдаемым выигрышем по F1 этапов; устойчивое преимущество по всем связям или ветвям не установлено.

Рисунок 2. Содержание на больших проектах



Четыре свежих запуска: по одному на метод и проект, одинаковый backend deepseek-flash, T=0,2, предел \$2. FULL имеет более высокий Milestone F1 на обоих проектах. Эффект по ветвям и Trace различается. Полные Precision и Recall приведены в таблице раздела 6; график F1 не заменяет оценку полноты.

7. Большие проекты: структура и ресурсы

ФТ / метод	Секунды	Вызовы	Токены	Цена, \$
59 / OpenCode	613,1	141	17 699 749	0,149200
59 / FULL	459,5	118	1 455 979	0,234667
74 / OpenCode	1043,4	244	41 099 626	0,288357
74 / FULL	658,3	145	2 080 277	0,347056


FULL завершился быстрее на 25,1% при 59 ФТ и на 36,9% при 74 ФТ. Это время отдельных запусков, без доверительного интервала. Цена FULL выше соответственно на 57,3% и 20,4%. Большой объём повторяемого контекста OpenCode частично компенсировался кешированием, поэтому меньше токенов не обязательно означает меньшую цену.

ФТ / метод	Цепочки	V2	Ссылка	Служебный	Явное допущение
59 / OpenCode	59/59	671/671	509	162	0
59 / FULL	59/59	502/502	337	165	0
74 / OpenCode	74/74	972/972	771	201	0
74 / FULL	74/74	707/707	505	196	6

Оба метода получили 100% структурных цепочек и допустимых оснований V2. В таблице разделены ссылки, служебные элементы и явные неподтверждённые предположения без ссылки. У FULL на 74 ФТ шесть элементов относятся к последней категории; всего семь помечены unsupported, один также имеет ссылку. Ошибочных ссылок и отсутствующих оснований нет. Таким образом, V2=1 не означает, что каждый элемент подтверждён источником.

Разница Trace F1 на 59 ФТ не означает автоматически два потерянных требования OpenCode. При локальном разборе функции присутствовали, но были сгруппированы в UC иначе, чем в Gold. Сопоставление UC влияет на оценку связей. Числовой Trace и проверка явных структурных цепочек отвечают на разные вопросы.

Рисунок 3. Время и цена результата



На 59 и 74 ФТ FULL быстрее соответственно на 25,1% и 36,9%, но дороже на 57,3% и 20,4%. Это четыре отдельных наблюдения, без доверительных интервалов. Все четыре пакета доставлены без обрезаний. Длительность является метрикой; календарные даты и время суток на графике не показаны.

8. Серия размеров: исходные 24 попытки

Использованы шесть проектов руководителя: SCALE-001/005/006/010/011/015, соответственно 6/10/12/19/24/48 ФТ. По два повтора FULL и OpenCode. Все исходные попытки сохранены; диагностические повторы не включены в приведённые средние.


Группа	Метрика	FULL P/R/F1	OpenCode P/R/F1
6–10 ФТ	Actor	0,917 / 1,000 / 0,950	1,000 / 1,000 / 1,000
6–10 ФТ	UC	1,000 / 1,000 / 1,000	1,000 / 1,000 / 1,000
6–10 ФТ	Milestone	0,510 / 0,882 / 0,643	0,383 / 0,951 / 0,543
6–10 ФТ	Branch	0,167 / 0,667 / 0,167	0,049 / 0,667 / 0,075
6–10 ФТ	Trace	0,909 / 0,950 / 0,929	0,955 / 0,975 / 0,964
12–19 ФТ	Actor	1,000 / 1,000 / 1,000	0,875 / 0,875 / 0,875
12–19 ФТ	UC	1,000 / 1,000 / 1,000	1,000 / 1,000 / 1,000
12–19 ФТ	Milestone	0,395 / 0,857 / 0,536	0,273 / 0,875 / 0,416
12–19 ФТ	Branch	0,220 / 0,875 / 0,343	0,084 / 0,750 / 0,146
12–19 ФТ	Trace	0,974 / 0,974 / 0,974	1,000 / 1,000 / 1,000
24–48 ФТ	Actor	0,851 / 0,887 / 0,868	0,917 / 0,810 / 0,856
24–48 ФТ	UC	1,000 / 1,000 / 1,000	1,000 / 1,000 / 1,000
24–48 ФТ	Milestone	0,441 / 0,809 / 0,568	0,366 / 0,871 / 0,510
24–48 ФТ	Branch	0,550 / 0,417 / 0,473	0,188 / 0,750 / 0,296
24–48 ФТ	Trace	0,979 / 0,979 / 0,979	0,979 / 0,979 / 0,979

Формально принятые полные пакеты: FULL 9/12, OpenCode 11/12. FULL на 10 ФТ в первом повторе и 48 ФТ во втором остановился до Activity после неисправленных замечаний. OpenCode на 19 ФТ в первом повторе завершился обрезанием без пакета. FULL на 12 ФТ во втором повторе прерван после HTTP 402; его расход известен не полностью.

Средняя доставка структурных цепочек FULL/OpenCode: 0,75/1,00 для 6–10 ФТ; 1,00/0,75 для 12–19; 0,75/1,00 для 24–48. Эти числа учитывают отказы и не доказывают общее преимущество FULL по трассировке.

Известная цена серии — \$3,213963216; верхний учёт — \$3,381197916. Разница \$0,167234700 является резервом неизвестного расхода, а не измеренной ценой. Различия тарифных условий и исходов ограничивают выводы о сравнительной экономичности.

Рисунок 4. F1 и полнота этапов по размерам



У FULL F1 выше, а Recall ниже в каждой группе. Значит, улучшился баланс точности и полноты, но не доля найденных этапов эталона. Сначала усреднялись общие доступные повторы проекта, затем проекты с равным весом. Доступны 4, 2 и 4 пары по группам; по два проекта в каждой. Диагностические повторы не включены.

9. Температура и диагностические повторы

Температура управляет вариативностью выбора продолжения текста моделью. При $T=0$ ответы обычно менее вариативны, но абсолютная повторяемость не гарантируется. При ненулевой T возможны разные формулировки и сценарные решения. Температура не меняет алгоритм валидаторов или лимит исправлений.


Пилот: два других проекта на 7 и 9 ФТ, два метода, $T=0/0,2/0,7$, два повтора — 24 запланированные попытки. Завершено 16: восемь при $T=0$ и по четыре при $T=0,2$ и $0,7$. Восемь не начаты из-за бюджетного барьера. Известный расход \$1,004585226; обрезаний нет. FULL формально принят в 8/8, OpenCode — в 7/8.

Заранее заданное правило выбора: при неполной или неуспешной сетке либо отсутствии практического прироста сохраняется 0,2. Поэтому 0,2 — фиксированная рабочая настройка, а не доказанный оптимум. $T=1$ не проверялась. Повторы на $T=0$ не используются как независимая выборка для сильных статистических выводов. Ненулевая температура тоже сама по себе не доказывает независимость.

После исходной серии размеров отдельно повторены четыре проблемные позиции: FULL10 r1, OpenCode19 r1, FULL12 r2, FULL48 r2. Все четыре новые попытки дали полный пакет, цепочки и $V2=1$, без обрезаний; цена новых попыток \$0,297469080. Это показывает возможность успешного завершения повторного запуска, но не исправляет статистику первоначальных 24 попыток и не доказывает устранение причины отказов.

Все исходные и новые task ID, метрики P/R/F1 и ресурсы доступны в числовом приложении. Для двух отказов FULL сохранённый UC-пакет допускает часть Gold-оценок; это не превращает его в полный пакет с Activity. Неизвестный исторический расход остаётся неизвестным и после успешного диагностического повтора.

Рисунок 5. Выполнение температурного пилота



Суммарно завершены 16 из 24 попыток двух методов на проектах с 7 и 9 ФТ. Восемь не начаты из-за бюджетного барьера. Столбцы показывают объём проверки и формальную приёмку, а не смысловое превосходство температуры. По заранее заданному правилу при неполной сетке сохранена T=0,2; оптимум не объявляется.

10. Ответ на замечания комиссии

1. «Отсутствует нормальный бейзлайн». Добавлены запрос с одной правкой, разбиение по UC и настоящий OpenCode Build. На историческом DEV20 по общей V1-проверке: один запрос 0/60; одна правка 59/60; разбиение 0/60; FULL 59/60. Это другая серия и другой способ итоговой проверки, чем прежние 2/60 и 60/60; числа не подменяются. Ничья с одной правкой учтена в выводах.

2. «Лимит там выставлен 8000 токенов». Новые исследовательские серии используют 131072 выходных токена на ответ с фиксацией причины остановки. Старый демонстрационный CLI-лимит не используется для описания этих опытов. Четыре cap2 ответа завершились без обрезаний.

3. «Любое разбиение на части промта ... решает эту проблему». Разбиение выделено в самостоятельный baseline без критика. Размер ответа и формальная приёмка разделены. Сам по себе отказ разбиения не доказывает необходимость критика. Контроль на заданных ответах проверяет механизм ограниченного исправления, но не качество LLM.

4. «Мотивация ... никогда не проверялось, поскольку нет разметки человеком». Опубликованы все пять P/R/F1 и разделены структурная корректность и смысл. В отдельном внешнем опыте 11 формально принятых FULL-пакетов всё же дали неуспешную кодогенерацию. Это обосновывает необходимость внешней проверки, но не доказывает преимущество FULL. Независимая экспертная оценка остаётся открытым пунктом.

5. «Не называть независимыми запуски на температуре 0». Новые сравнения выполнены при фактической $T=0,2$; проведён отдельный калибровочный пилот. Для малых серий не заявлены статистическая значимость и универсальная устойчивость.

6. «Фреймворк ... не используются как бейзлайны». Выполнено числовое сравнение с OpenCode Build. NOMAD не запускался и остаётся только теоретическим аналогом. Сравнение backend-моделей отделено от сравнения методов.

11. Воспроизводимость и опубликованные изменения

Опубликованы исправления промптов, передача исходного контекста, проверки терминального потока, исследовательский профиль, внешний адаптер, учёт ответов и регрессионные тесты. Закрытые требования, приватные журналы и API-ключи не публикуются.

Обычный CLI FULL сохраняет прежний профиль. FULL_NEW использовал `terminal_consistency_deps` с `contract_version=V2` и `CacheAwareFullClient`. Адаптер передавал $T=0,2$ даже при запросе роли $T=0$. Контракт V2 температуру не меняет. Предел \$2 задавался обёрткой серии, не старым адаптером по умолчанию.

`results_snapshot.json` содержит числа и статусы четырёх серий, включая не начатые позиции и отказы. Хеши `summary.json` фиксируют происхождение. Срез позволяет проверить сводные числа, но не повторно оценить закрытый Gold.

Безопасная проверка установки: `poetry install --with evaluation`, затем демонстрация B0_RULE на `examples/event_signup_specification_req.json`. Этот режим не использует API. Локальные регрессионные тесты запускаются через `poetry run pytest`. Сетевой запуск требует отдельного разрешения `--allow-live` и собственных лимитов.

Заключение

Реализован проверяемый промежуточный пакет требований, сценариев и диаграмм. Исправлен поток исходного контекста и обратной связи, усилены проверки потока Activity и постановка сравнения. Добавлен внешний агентный baseline с общим backend и явными ограничениями.


На двух больших проектах наблюдается преимущество FULL по Milestone F1 и времени отдельных запусков. Цена выше; результаты по ветвлениям и трассировке неоднородны. В серии размеров более высокий F1 не означает более высокий Recall. Наиболее обоснованный итог — работоспособная реализация и измеренные преимущества в обозначенных условиях, с сохранением отрицательных результатов и границ применимости.

Дополнение А. Исходная серия: 54, 59 и 74 ФТ

Исходная серия: три больших проекта

ИТМО

DeepSeek Flash, T=0,2, предел \$1. Проекты руководителя: SCALE-016 / 54 ФТ, SCALE-017 / 59 ФТ, SCALE-020 / 74 ФТ.



* OpenCode на 59 ФТ остановил бюджетный контроллер. Оценён сохранённый пакет. Все исходы включены. Milestone F1 у FULL выше на трёх проектах. Branch F1 на 59 и 74 ФТ ниже, чем у OpenCode.

36


Рисунок 6 — исходная серия с пределом \$1 на попытку. Это шесть запусков на трёх проектах, отдельно от новых четырёх запусков с пределом \$2. Изображение перенесено из предоставленных материалов; округления и исходные подписи сохранены.

Полученный положительный результат: Milestone F1 у FULL выше на всех трёх проектах — примерно 0,62 против 0,40; 0,66 против 0,37; 0,69 против 0,46. Это наблюдаемое преимущество по балансу точности и полноты смысловых этапов относительно кандидата Gold.

Trace F1 у FULL выше на 59 и 74 ФТ, на 54 ФТ — ничья. Однако OpenCode на 59 ФТ остановлен бюджетным контроллером, а F1 ветвей у FULL на 59 и 74 ФТ ниже. Поэтому рисунок поддерживает частные результаты при пределе \$1, но не общее превосходство по трассировке. Новая серия с пределом \$2 проверяет другой ресурсный режим и приведена отдельно в основном тексте.

Что выполнено: проведено числовое сравнение собственного метода с внешней агентной системой на крупных входах. Это отвечает требованию сравнивать метод с методом, а не только FULL с единичным вызовом LLM.

Доставка и структурные цепочки



Е3: на 59 и 74 ФТ оба метода дали 100% цепочек

Сначала повторы внутри проекта, затем равный вес проектов. 75% — не доля каждого готового пакета. Нет пакета: 0. Неизвестный частичный: NA, вне среднего. Е1: общие пары 4 / 3 / 4.

Рисунок 7 — исходные 24 попытки на шести проектах. Полный принятый пакет доставлен в 9 из 12 попыток FULL и 11 из 12 OpenCode. Значения 0,75 и 1,00 — средние с учётом известных отказов, а не полнота каждого отдельного готового пакета.

В группе 12–19 ФТ наблюдаемая доставка цепочек FULL выше: 1,00 против 0,75. В двух других группах выше OpenCode. На больших проектах 59 и 74 ФТ в отдельной sar2 серии оба метода дали полные цепочки.


Что выполнено: реализована и проверена метрика сквозной структурной трассировки, а не только наличие правильного JSON. Отказы и неизвестный частичный результат не скрыты. Польза этой проверки — она отличает качество сохранённого фрагмента от способности доставить полный аналитический пакет. Рисунок не подтверждает преимущество FULL по надёжности доставки в целом.

Дополнение В. Ресурсы по шести проектам

Время и расчётная стоимость по проектам

ИТМО

Средние общих известных повторов. Включены известные неуспехи, поэтому меньшие затраты не означают лучший результат.



Часть запусков оплачена по половинному тарифу. Цена зависит от тарифа, кеша и исхода попытки.
Для 12 ФТ одна известная пара. Прерванный FULL 12 ФТ/r2 не получает нулевую цену.

37

Рисунок 8 — время и расчётная цена общих известных повторов исходной серии размеров. Для каждого проекта усредняются доступные парные попытки. На 12 ФТ используется одна известная пара; неизвестный расход второго FULL не приравнивается к нулю.

Наблюдение в пользу FULL: среднее время попытки меньше на пяти из шести проектов, особенно на 48 ФТ — около 5,7 против 16,7 минуты. Однако в эти средние включены известные неуспехи. Быстро завершившийся отказ не равен быстрой доставке правильного пакета.

Цена FULL ниже не на каждом проекте. На стоимость влияют кеш, тариф и исход попытки; часть запусков оплачена по половинному тарифу. Поэтому корректный вывод — измерены ресурсные различия при конкретных условиях. Для сравнения именно успешно доставленных больших пакетов следует использовать рисунок 3 и дополнение Ж.

Что выполнено: сравнение охватывает время и стоимость вместе с качеством и успешностью. Это позволяет обсуждать компромисс качества и затрат, а не выбирать только удобный показатель.

Дополнение Г. Температура: содержание на 9 ФТ





Рисунок 9 — Milestone F1 на одном проекте с 9 ФТ. Оранжевая линия обозначает FULL, синяя — OpenCode. Закрашенные точки относятся к первому повтору; дополнительные контурные точки при $T=0$ показывают второй повтор. Для $T=0,2$ и $T=0,7$ вторых повторов нет.

Числа сверены с сохранённым срезом. Первый повтор FULL/OpenCode: при $T=0$ — 35,0% / 29,4%; при $T=0,2$ — 34,0% / 27,7%; при $T=0,7$ — 34,4% / 32,2%. Второй повтор при $T=0$: 34,7% / 35,3%.

Положительный результат: в первом повторе FULL показал более высокий F1 этапов на всех трёх проверенных температурах. Вторым повтор при $T=0$ показывает, что порядок методов может измениться. Ни график, ни неполный пилот не устанавливают оптимальность $T=0,2$.

Что выполнено: влияние температуры проверено отдельным опытом. Значение 0,2 сохранено по заранее заданному правилу при неполной сетке, а не выбрано задним числом как победитель. Пилот и ограничения его полноты показаны в разделе 9 и на рисунке 5.

Дополнение Д. Различие правил V1 и V2



* В v1 также допускается явно отмеченное предположение.
V2 дополнительно проверяет ссылки УС на НФТ; её оптимальность не доказана.

Рисунок 10 объясняет изменение формального контракта. Бизнес-действие «Показать форму» обязано иметь основание в сценарии. Пустой служебный переход от начала или к концу может не обозначать отдельный сценарный шаг. V2 допускает такое исключение при перечисленных на рисунке условиях.

Полученный технический результат: правило точнее различает бизнес-содержание и служебные элементы графа. Существование ID, внутренние переходы, выходы решений и ссылки УС на НФТ продолжают проверяться. Это не разрешение оставлять произвольные действия без основания.

Что выполнено: уточнены детерминированные проверки и явно зафиксирована версия оценки. Изменение правил применяется одинаково к сравниваемым методам. Улучшение приёмки после смены контракта нельзя автоматически считать улучшением содержания модели; версии и переоценка старых ответов разделены.

Дополнение Е. Проверка ограничения ответа



Рисунок 11 — историческая проверка на 36 и 74 ФТ: четыре метода, всего восемь попыток. Пределы: 131072 выходных токена на ответ, 2000000 токенов и 512 вызовов на попытку. Это отдельный ресурсный профиль, не настройки новых серий.

Все 278 ответов завершились с причиной stop, без зарегистрированных обрезаний или остановок по ресурсам. Разбиение уменьшило максимальный ответ, но не обеспечило прохождение V1. Значит, эти формальные отказы нельзя объяснить зарегистрированным обрезанием.

Положительный результат: FULL и baseline с одной правкой приняты на обоих проектах. У FULL максимальный ответ существенно меньше, чем у one-shot. Отдельный причинный эффект LLM-критика этим не выделен.

Что выполнено: проверены причины завершения, усилен baseline и выделен эффект разбиения. Это отвечает замечаниям о лимите 8000 и смещении длины ответа с качеством.

Итоговая серия на больших проектах



59 и 74 ФТ. По одному новому запуску метода. Все четыре завершились.

ФТ	Метод	Минуты	Цена, \$	Вызовы	Обрезания
59	OpenCode	10,2	0,149	141	0
59	FULL	7,7	0,235	118	0
74	OpenCode	17,4	0,288	244	0
74	FULL	11,0	0,347	145	0

FULL быстрее на 25,1% при 59 ФТ и на 36,9% при 74 ФТ

Расчетная цена выше на 57,3% и 20,4%. Цена учитывает кеш.
Предел \$2 одинаков. Здесь показаны отдельные запуски, без оценки устойчивости.

29

Рисунок 12 повторяет итоговую ресурсную таблицу в форме, пригодной для обсуждения с научным руководителем. Четыре свежие попытки на 59 и 74 ФТ завершились без обрезаний; предел \$2 одинаков для обоих методов. Модель deepseek-flash, T=0,2, thinking отключён.

Подтверждённый результат: FULL быстрее на 25,1% и 36,9% в этих отдельных запусках и использует меньше вызовов. Одновременно расчётная цена выше на 57,3% и 20,4%. Качество оценивается не по этой таблице, а по пяти группам P/R/F1 и структурным метрикам разделов 6–7.

Что выполнено: для внешнего сравнения показаны завершение, реальные ограничения и ресурсы вместе с результатами качества. Более высокий Milestone F1 и меньшее время на двух больших проектах — обоснованные частные преимущества FULL. Малое число запусков не позволяет называть их универсальными или статистически устойчивыми.

Итог по задачам и замечаниям

Задача 1 — типизированные модели: реализованы требования, UC, шаги, Activity и ссылки трассировки. Проверка: модели данных, валидаторы и сохранённые структурированные пакеты.

Задача 2 — два графа и оркестратор: реализованы Use Cases и Activity, шесть ролей и ограниченные циклы исправления. Проверка: схема, код и регрессионные тесты. Контекст и обратная связь исправлены.

Задача 3 — проверки и исправления: реализованы схемы, ссылки, терминальный поток, критика и редактор. Проверка: правила V1/V2, тесты и сохранённые исходы. Оптимальность ровно двух исправлений на новых проектах отдельно не установлена.

Задача 4 — benchmark и метрики: подготовлены разметка и оценщик; результаты разделены по категориям и размерам. Публикуются пять P/R/F1 и структурные показатели. Gold остаётся авторским кандидатом, а не независимой экспертной оценкой.

Задача 5 — сравнение: выполнено с внутренними baseline и внешним OpenCode Build при явно заданных условиях. Измерены качество, доставка, трассировка, время и стоимость. На двух больших проектах FULL имеет выше Milestone F1 и меньше время запуска; результаты по остальным показателям неоднородны.

Итог: основные инженерные задачи реализованы, экспериментальное сравнение проведено, существенные замечания к постановке учтены. Получены измеренные преимущества по отдельным важным показателям. Независимая оценка смысла, устойчивое общее превосходство по трассировке и переносимость эффекта на другие модели остаются открытыми исследовательскими вопросами. Поэтому формулировка «выполнены все требования комиссии и доказано общее превосходство» была бы сильнее имеющихся данных.

Приложение. Источники и проверяемость

Источниками обновления служат локальные зафиксированные протоколы, исходный код, контрольные срезы результатов и прежний технический отчёт. Новые статьи и внешние материалы для этого обновления не ищались. Новые платные эксперименты не проводились.

Контрольный срез	SHA-256 исходного summary.json
large_cap2	2ff1b8033876ae5027f12da45c7336b2 0f169bba87b4a6c57820e067ce6ba30f
sizes_original24	06e3ab5858847dc74e75614f378cd577 242e594627acae864b8c9453f74d61a1
temperature_pilot	a6d7d852085774fa65ca93ee7c3fb091 6bc46cf3a8a97851e5a6793b05c47649
diagnostic_retries	8289e27341aecb1e9411a64d89b2e28e a6f12de4cbafa4400b8bf6ab4ea94b37

Карта опубликованных материалов: README.md — краткая постановка и запуск; docs/final/CHANGES_AND_REVIEW.md — замечания комиссии и ответы; docs/final/results/results_snapshot.json — точные числовые данные; docs/final/REPORT_SOURCE.md — исходный текст отчёта; scripts/build_public_report.py — сборка PDF.

Встроенные таблицы формируются из числового приложения, а не переписываются вручную. Первоначальные отчёты и результаты сохранены как исторические. Новая публикация не меняет условия уже выполненных опытов и не выбирает лучший ответ из первоначального и диагностического запуска.

Оформление основано на прежнем техническом отчёте: А4, чёрный текст, Times New Roman, основной кегль 14, межстрочный интервал 1,5, поля слева 3 см, справа 1,5 см, сверху и снизу 2 см. Календарные даты и время суток в новом документе отсутствуют; длительность запусков сохранена как существенная метрика.